ARC-AGI-2 High-Score Systems, Claims and Sources

System-by-system catalogue · GitHub code · research papers · Hugging Face traces · 6 October 2026

এই রিপোর্টটি শুধু ARC-AGI-2-এর সোর্স-যুক্ত উচ্চ-স্কোরিং solver/system এবং সংশ্লিষ্ট প্রকাশিত কনফিগারেশন নিয়ে। ২০২৫ সালের Kaggle বিজয়ী, ২০২৬ Kaggle public leaderboard snapshot, সাধারণ hosted-model ranking, GPU strategy বা experiment plan এখানে রাখা হয়নি।

স্কোরের পাশে split দেওয়া আছে। Public evaluation (১২০টি প্রকাশিত task), ARC Prize verified semi-private এবং Kaggle 2026 private আলাদা মূল্যায়ন; একটির ৯৭% মানে অন্যটির ৯৭% নয়।

প্রমাণের চিহ্ন: [VERIFIED] = ARC Prize-verified semi-private; [PAPER] = প্রকাশিত ২০২৬ গবেষণাপত্রে ফল; [REPO + TRACES] = source + logs; [SELF-REPORT] = লেখকের দাবি; [CAVEAT] = মূল্যায়ন/পুনরুৎপাদনের সীমাবদ্ধতা।

A. ARC Prize verified semi-private — code ও paper-সহ

1. Johan Land / Beetree — 72.9% verified

Score: 72.9% semi-private; একই paper-এ 76.1% public evaluation

Model: GPT-5.2, Gemini ও Claude-ভিত্তিক বহু-model search/judging ensemble

Status: [VERIFIED semi-private] + [PAPER] + [OPEN CODE]

Text, image ও code—ভিন্ন reasoning modality থেকে প্রার্থী তৈরি; সব candidate trace একই long-context judge-এ তুলনা করে minority correct hypothesis উদ্ধার করে।

GitHub (solver): https://github.com/beetree/ARC-AGI

Research paper (2026): https://arxiv.org/abs/2606.31543

Results file: https://github.com/beetree/ARC-AGI/blob/main/docs/RESULTS.md

CAVEAT: 72.9% হচ্ছে পৃথক semi-private verification; 76.1% হলো public evaluation। কোনো স্কোরই ২০২৬ Kaggle private submission score নয়।

B. 95% বা বেশি — ২০২৬ ARC-AGI-2 public evaluation

2. Confluence Labs — 97.92%

Score: 97.92% public evaluation; ~US$11.77/task reported

Model: Gemini CLI agent ensemble (12 agents/input); E2B sandboxes

Status: [SELF-REPORT] + [OPEN CODE]

Program synthesis, independent agents, multiple refinement iterations ও answer voting। Repo-র run.sh-এ ফলপ্রাপ্ত configuration এবং single-task smoke command আছে।

GitHub (complete solver): https://github.com/confluence-labs/arc-agi-2

Core solver directory: https://github.com/confluence-labs/arc-agi-2/tree/main/gemini-cli-solver

CAVEAT: নিজস্ব public-eval measurement। API ও sandbox service দরকার; সরাসরি offline Kaggle 2026 private submission নয়।

3. Squeeze-Evolve — 97.5%

Score: 97.5% public evaluation; best reported cost ~US$5.93/task

Model: Gemini 3.1 Pro + Gemini 3 Flash; model-selective recombination

Status: [PAPER] + [OPEN FRAMEWORK]

Verifier-free evolutionary inference: candidate diversity অনুযায়ী hard cases শক্তিশালী model-এ, easy cases সস্তা model-এ; consensus হলে lightweight aggregation। COLM 2026 paper-এ ARC-AGI-V2 97.5% ফল ও খরচের টেবিল আছে।

GitHub (framework): https://github.com/squeeze-evolve/squeeze-evolve

Research paper (2026): https://arxiv.org/abs/2604.07725

Paper HTML — ARC-AGI-V2 §6.3: https://arxiv.org/html/2604.07725v2

CAVEAT: GitHub-এ framework code আছে; README-তে ARC-specific ready-to-run benchmark recipe প্রকাশিত benchmark list-এ নেই। তাই সম্পূর্ণ ARC run সরাসরি reproducing নিশ্চিত ধরে নেওয়া যাবে না।

4. Athanor — 95.7%

Score: 95.7% public evaluation; ~US$3.12/task

Model: Anthropic-powered solver + independent Gemini reviewer

Status: [SELF-REPORT] + [OPEN CODE + RUN TRACES]

Python code দিয়ে training transformations যাচাই, independent artifact-only reviewer, agent contexts-এ reasoning না পাঠিয়ে verified artifact exchange, এবং checkpoint-resume।

GitHub (solver): https://github.com/dastin359/athanor

Reported per-task results: https://github.com/dastin359/athanor/blob/main/RESULTS.md

Released run checkpoints: https://github.com/dastin359/athanor/tree/main/release_runs

Paper directory: https://github.com/dastin359/athanor/tree/main/paper

CAVEAT: ৯৫.৭% লেখকের public-eval report; publisher-independent semi-private result নয়। Trace-সহ replay সম্ভব হলেও model randomness ও external API dependency আছে।

5. Imbue / Darwinian Evolver — 95.1%

Score: 95.1% public evaluation (Gemini 3.1 Pro); ~US$8.71/task

Model: Gemini 3.1 Pro; একই framework-এ Gemini 3 Flash, Kimi K2.5

Status: [SELF-REPORT] + [OPEN FRAMEWORK]

প্রতিটি task-এর জন্য executable Python solution-এর population, fitness-based parent selection, mutation এবং নতুন code verification। একই system-এ Flash 61.4% ও open-weight Kimi K2.5 34.0% reported।

GitHub (evolution code): https://github.com/imbue-ai/darwinian_evolver

2026 method/results article: https://imbue.com/blog/2026-02-27-arc-agi-2-evolution

CAVEAT: Author জানায় semi-private submission evaluation hold-এ ছিল; 95.1% তাই semi-private verified নয়। Kimi-র open weights থাকলেও বর্ণিত result API orchestration দিয়ে মাপা হয়েছে।

C. 80–95% public-eval systems — original code first

6. Noemon — 92.5%

Score: 92.5% public evaluation (GitHub README); ~US$3.90/task

Model: Gemini 3.1 Pro

Status: [SELF-REPORT] + [OPEN CODE] [SPLIT CAVEAT]

Reasoner agent rule লেখে, Validator training pairs-এ rule পরীক্ষা করে; self-consistent answer পুনরায় আসলে accept, অন্যথায় final judge candidate বেছে নেয়। Agent state ও checkpointing আছে।

GitHub (solver): https://github.com/noemon/noemon-arc-agi

Implementation directory:
https://github.com/noemon/noemon-arc-agi/tree/main/src/arc_agi_benchmarking/noemon

CAVEAT: Repo-তে public eval বলা হলেও indexed community-label-এ public train উল্লেখ দেখা যায়। প্রকাশিত split ও benchmark-run artifact স্বাধীনভাবে মিলিয়ে না দেখা পর্যন্ত verified public-eval দাবি হিসেবে ধরে নেওয়া উচিত নয়।

7. ARCgentica / Symbolica — 85.28%

Score: 85.28% public evaluation (Opus 4.6 High); ~US$6.94/task

Model: Claude Opus 4.6 (120k High); alternate GPT-5.2 XHigh

Status: [SELF-REPORT] + [OPEN CODE + LOGS]

Python REPL-ভিত্তিক program synthesis ও recursively spawned sub-agent দিয়ে hypotheses পরীক্ষা। একই codebase-এর GPT-5.2 XHigh configuration 70.27% public eval reported।

GitHub (ARC agent): https://github.com/symbolica-ai/arcgentica

Source module: https://github.com/symbolica-ai/arcgentica/tree/main/arc_agent

Original 2026 results article: https://www.symbolica.ai/blog/arcgentica

Published result logs: https://github.com/symbolica-ai/arcgentica/tree/main/output/2025/anthropic/claude-opus-4-6/final

CAVEAT: Public-eval self-report। Repo-র output folder-এ "2025" লেখা থাকলেও ফলের write-up ফেব্রুয়ারি ২০২৬; এটিকে ২০২৫ Kaggle private result বলা ভুল।

D. 2026 code-linked alternative: REPL / open-model variants

8. Agentic Coding / Stateful REPL — 68.33%

Score: 68.33% full 120-task public evaluation; 73.36% কেবল 107-task subset

Model: GPT-5.2 XHigh; GPT-OSS-120B, MiniMax M2.1 ablations

Status: [OPEN CODE] + [HUGGING FACE RAW TRACES]

Stateful IPython REPL দিয়ে Python transformation function বানানো, পরীক্ষা ও সংশোধন। একই framework-এর open-weight GPT-OSS-120B variant 26.39%, MiniMax M2.1 10.56% reported।

GitHub (reproduction source): https://github.com/gutfeeling/arc-agi-2-submission

Hugging Face (prompts, tool calls, outputs): https://huggingface.co/datasets/arcagi2/arcagi2-agentic-coding-publication

Research write-up (2026): https://pivotools.github.io/pivotools-quarto-blog/posts/agentic_coding_arc_agi/

CAVEAT: 73.36% সংখ্যাটি 107টি task-এর subset score, full public evaluation score নয়। Full-set headline 68.33%—HF dataset card-এর পার্থক্যটি গুরুত্বপূর্ণ।

E. আলাদা করে রাখার মতো ২০২৬ paper claim (comparability caveat)

9. Multi-Stage Rule-Chaining — >95% manuscript claim

Score: Paper claim: 230/240 test outputs solved; >95% stated (split/metric not independently validated)

Model: Three-stage deterministic, compositional & structural rule solvers

Status: [PAPER] + [KAGGLE CODE] [CAVEAT: NOT RANKABLE]

জ্যামিতি, রং ও object rule induction; block composition; hierarchical structural reasoning—এই তিন ধাপে fallback-based solver। সেপ্টেম্বর ২০২৬-এর manuscript-এ 995/1000 training pass ও 230/240 test-output claim আছে।

Research paper (2026): https://arxiv.org/abs/2609.10654

Author-linked Kaggle code: https://www.kaggle.com/code/deblina4kaggle/995-tasks-solutions

CAVEAT: এই >95% সংখ্যাকে Confluence/Squeeze-এর 120-task public-eval score বা 2026 Kaggle private score হিসেবে গণনা করিনি; manuscript-এ আলাদা সংখ্যা/সেট দেওয়া হয়েছে এবং independent ARC Prize verification পাওয়া যায়নি।

F. Evidence notes — অপ্রাসঙ্গিক ranking বাদ

এই catalogue-এ ২০২৫ Kaggle winners, ২০২৬ Kaggle public leaderboard-এর anonymous team snapshot, অথবা GitHub/paper-বিহীন hosted model-only score নেই। একটি system-এর ভিন্ন model variant একই entry-তে রাখা হয়েছে, যাতে কৃত্রিমভাবে ২৫টি "ভিন্ন system" তৈরি না হয়।

Public evaluation results প্রায় সবই গবেষক/লেখক-রিপোর্টেড। ARC Prize নিজেই বলে community public set-এর score সাধারণত self-reported; কেবল semi-private run তাদের verified label পেতে পারে। Kaggle 2026 scoring-এ Internet নেই, তাই উপরের commercial API agent-গুলোর public-eval score-কে সরাসরি Kaggle offline runnable solution বলা যায় না।

Verification references:

ARC Prize — Community verification policy: https://arcprize.org/leaderboard/community

ARC Prize 2026 — no Internet at Kaggle evaluation: https://arcprize.org/competitions/2026

Official ARC-AGI-2 public task data: https://github.com/arcprize/ARC-AGI-2

Appendix — Direct URL Index (deduplicated, clickable)

শুধু এই রিপোর্টে প্রকৃতপক্ষে উদ্ধৃত original source URLs। Company homepage বা বারবার একই generic organization link দিয়ে তালিকা বড় করা হয়নি।

1. https://github.com/beetree/ARC-AGI
2. https://arxiv.org/abs/2606.31543
3. https://github.com/beetree/ARC-AGI/blob/main/docs/RESULTS.md
4. https://github.com/confluence-labs/arc-agi-2
5. https://github.com/confluence-labs/arc-agi-2/tree/main/gemini-cli-solver
6. https://github.com/squeeze-evolve/squeeze-evolve
7. https://arxiv.org/abs/2604.07725
8. https://arxiv.org/html/2604.07725v2
9. https://github.com/dastin359/athanor
10. https://github.com/dastin359/athanor/blob/main/RESULTS.md
11. https://github.com/dastin359/athanor/tree/main/release_runs
12. https://github.com/dastin359/athanor/tree/main/paper
13. https://github.com/imbue-ai/darwinian_evolver
14. https://imbue.com/blog/2026-02-27-arc-agi-2-evolution
15. https://github.com/noemon/noemon-arc-agi
16. https://github.com/noemon/noemon-arc-agi/tree/main/src/arc_agi_benchmarking/noemon
17. https://github.com/symbolica-ai/arcgentica
18. https://github.com/symbolica-ai/arcgentica/tree/main/arc_agent
19. https://www.symbolica.ai/blog/arcgentica
20. https://github.com/symbolica-ai/arcgentica/tree/main/output/2025/anthropic/claude-opus-4-6/final
21. https://github.com/gutfeeling/arc-agi-2-submission
22. https://huggingface.co/datasets/arcagi2/arcagi2-agentic-coding-publication
23. https://pivotools.github.io/pivotools-quarto-blog/posts/agentic_coding_arc_agi/
24. https://arxiv.org/abs/2609.10654
25. https://www.kaggle.com/code/deblina4kaggle/995-tasks-solutions
26. https://arcprize.org/leaderboard/community
27. https://arcprize.org/competitions/2026
28. https://github.com/arcprize/ARC-AGI-2